

Classificando a Qualidade de Vinhos com Machine Learning

Análise Exploratória de Dados

Apresentação Executiva · POSTECH Tech Challenge Fase 2

Grupo 7:

Camila de Oliveira - RM 371409

Lucas Zucoloto Soares Valbusa - RM 373425

Luysa Brito de Paiva Lima - RM 373813

Tatiana Regina da Silva - RM 373518

Vanessa Gomes Cardoso - RM 373426

Classificando a Qualidade de Vinhos com Machine Learning

Análise Exploratória de Dados

Apresentação Executiva · POSTECH Tech Challenge Fase 2

1.143 vinhos analisados

11 variáveis físico-químicas

3 modelos comparados

O problema que queremos resolver

Contexto da indústria vitivinícola

O desafio atual

- Qualidade avaliada por especialistas humanos
- Processo subjetivo — depende da experiência do enólogo
- Demorado e custoso para escalar
- Difícil de padronizar entre lotes e safras



A solução proposta

- Usar dados físico-químicos de rotina (pH, álcool, acidez...)
- Treinar um modelo de Machine Learning para classificar a qualidade
- Prever: alta qualidade (nota ≥ 7) ou baixa/média (nota < 7)
- Triagem automática antes da avaliação sensorial

Os dados que temos

Wine Quality Dataset — Kaggle

1.143

amostras de vinho tinto

11

variáveis físico-químicas

3–8

escala de notas de qualidade

0

valores nulos — dataset limpo

Variáveis disponíveis no dataset:

Acidez fixa

Acidez volátil

Ácido cítrico

Açúcar residual

Cloretos

SO₂ livre

SO₂ total

Densidade

pH

Sulfatos

Teor alcoólico

→ **Qualidade (alvo)**

Simplificando a pergunta

De notas numéricas para uma decisão binária

Transformação da variável alvo

Nota ≥ 7

Alta qualidade


Nota < 7

Baixa/Média qualidade

⚠ Atenção: dataset desbalanceado

Apenas 13,9% dos vinhos são de alta qualidade. Sem tratamento, o modelo aprenderia a sempre responder "baixo/médio" e ainda teria 86% de acurácia aparente — mas seria inútil.


Distribuição das classes



■ Baixa/Média (86,1%) ■ Alta qualidade (13,9%)

Quais variáveis mais influenciam a qualidade?

Correlação de Pearson com a nota de qualidade




 Correlação positiva — mais desse componente → vinho melhor

 Correlação negativa — mais desse componente → vinho pior

Teor alcoólico: o maior indicador de qualidade

Correlação +0,484 com a qualidade — 23,6% de importância no modelo

Distribuição por faixa de teor alcoólico



11,5%

Média de álcool
nos vinhos bons

72%

dos vinhos bons
com álcool > 10%

#1

Implicação para produção:

Monitorar o álcool ao final da fermentação. Lotes
abaixo de 10,5% merecem revisão.

Acidez volátil: o principal sinal de defeito

Correlação -0,407 — vinhos bons têm 29% menos acidez volátil

Vinhos de ALTA qualidade

0,40 g/L

média de acidez volátil


-29%

Vinhos de BAIXA qualidade

0,55 g/L

média de acidez volátil

Distribuição por faixa de acidez volátil (g/L)




O que causa acidez volátil alta?

- Contaminação bacteriana durante a fermentação
- Oxidação do vinho sem proteção adequada
- Higiene insuficiente nos equipamentos

Comparativo completo: vinhos bons vs comuns

Diferença percentual na média de cada variável



Legenda:

- Vinhos bons têm MAIS desse componente
- Vinhos bons têm MENOS desse componente



Maior diferença:

Ácido cítrico (+57%) — frescor e equilíbrio



Maior risco:

Acidez volátil (-29%) — sinal de vinagre




Menos relevante:

pH e Densidade — diferença < 1%

Qualidade e consistência dos dados

Análise de valores extremos e distribuição

Outliers por variável (método IQR)



Crítico: açúcar e cloretos

110 e 77 outliers respectivamente. Distribuições com assimetria severa. Tratados com Winsorização (percentil 1–99).

Moderado: 4 variáveis

Sulfatos, acidez fixa, SO₂ total e densidade com outliers moderados. Normalização absorve o impacto residual.



Ação: sem remoção de linhas

Com apenas 1.143 amostras, optamos por ajustar os extremos em vez de remover linhas — preservando cada amostra.

O modelo que desenvolvemos

Comparação entre três algoritmos de Machine Learning

Modelo	F1-Score	Precision	Recall	AUC-ROC
Logistic Regression	0.473	0.361	0.688	0.856
XGBoost	0.618	0.583	0.656	0.912
✅ Random Forest	0.638	0.595	0.688	0.918



O que isso significa para a produção?

Recomendações baseadas nos dados

01 Monitorar o teor alcoólico

Medir ao final da fermentação. Lotes abaixo de 10,5% têm alta probabilidade de qualidade inferior e devem ser revisados antes do envelhecimento.

Impacto: +12,3% nos vinhos bons

02 Controlar a acidez volátil

Implementar medição rotineira durante o processo. Valores acima de 0,6 g/L indicam contaminação bacteriana — intervenção precoce pode salvar o lote.

Impacto: -28,6% nos vinhos bons

03 Ajustar sulfatos na faixa ideal

Manter entre 0,65 e 0,85 g/L. Abaixo disso, o vinho fica desprotegido contra oxidação. Acima, o sabor é comprometido.

Faixa ideal identificada nos dados

04 Usar o modelo como triagem

Classificar lotes automaticamente com base em medições de rotina. Direcionar candidatos a alta qualidade para avaliação sensorial completa do enólogo.

AUC-ROC 0.918 — 92% dos comuns identificados

Conclusão

Dados químicos podem prever a qualidade do vinho

0.918

AUC-ROC do
melhor modelo

69%

vinhos bons
identificados

92%

vinhos comuns
classificados certo

4

variáveis-chave
para focar

Álcool · Acidez Volátil · Sulfatos · Ácido Cítrico

As quatro variáveis que mais distinguem um vinho de alta qualidade