



RELATÓRIO EXECUTIVO

WINE QUALITY CLASSIFICATION



GRUPO 7 | TECH CHALLENGE

Camila de Oliveira - RM 371409
Lucas Zucoloto Soares Valbusa - RM 373425
Luyza Brito de Paiva Lima - RM 373813
Tatiana Regina da Silva - RM 373518
Vanessa Gomes Cardozo - RM 373426

TECH CHALLENGE FASE 2



1. Resumo executivo	3
2. Contextualização	3
2.1 Variável alvo	4
3. Análise Exploratória dos Dados	5
3.1 distribuição das variáveis	5
3.2 Distribuição da Qualidade por Faixas de Álcool e pH	6
3.3 Faixas complementares (acidez fixa, açúcar residual, ácido cítrico)	7
3.4 Correlações entre variáveis	7
4. Desenvolvimento dos modelos	8
4.1 Interpretação das Matrizes de Confusão	8
4.2 Análise das médias por classe	9
5. Otimização dos modelos	10
5.1 Ajuste do Threshold	11
5.2 Comparação das Estratégias de Otimização	11
6. modelo final	12
6.1 Principais variáveis identificadas	12
6.2 Aplicação prática	13
7. Apêndice	13
7.1 Repositório do Projeto	13
7.2 Vídeo Pitch	13
7.3 Apresentação	13

1. Resumo executivo

Com o crescimento da indústria vinícola e o aumento da competitividade do mercado, torna-se cada vez mais importante adotar processos que garantam a qualidade dos vinhos de forma eficiente e padronizada. Tradicionalmente, essa avaliação é realizada por especialistas, que analisam características sensoriais, como aroma, sabor, acidez e equilíbrio. Apesar de sua importância, esse processo demanda tempo, investimento e depende, em grande parte, da experiência desses profissionais.


Nesse contexto, o projeto tem como objetivo desenvolver um modelo de aprendizado de máquina capaz de classificar vinhos com base em suas características físico-químicas. O estudo foi desenvolvido a partir da análise de 1.143 amostras do Wine Quality Dataset, contendo 11 variáveis físico-químicas relacionadas às características dos vinhos.

Ao longo do projeto foram realizadas etapas de preparação dos dados, análise exploratória, tratamento dos dados e desenvolvimento de diferentes modelos de aprendizado de máquina. Como resultado, foi possível identificar padrões associados aos vinhos de maior qualidade e avaliar o potencial do uso dessas técnicas como ferramenta de apoio ao controle de qualidade na indústria vitivinícola.

2. Contextualização

A análise exploratória dos dados teve como objetivo compreender a distribuição das amostras e identificar características relevantes para o desenvolvimento dos modelos de aprendizado de máquina. Inicialmente, foi analisada a distribuição da variável de qualidade, verificando-se um desbalanceamento entre as classes.

A maior parte dos vinhos foi classificada como Baixa/Média qualidade, representando 86,1% das amostras do conjunto de dados. Em contrapartida, apenas 13,9% dos registros pertencem à categoria Alta qualidade.



Como consequência desse desbalanceamento, a acurácia não foi utilizada como principal métrica de avaliação, pois poderia indicar um desempenho elevado mesmo que o modelo apresentasse dificuldades para identificar corretamente os vinhos de alta qualidade.

Dessa forma, foram adotadas métricas mais adequadas para esse cenário:

Métricas	Explicação
F1-Score	utilizado como principal métrica do projeto, pois representa o equilíbrio entre Precision (proporção de vinho classificados como alta qualidade) e Recall (capacidade do modelo de identificar corretamente a alta qualidade), sendo mais apropriado para conjuntos de dados desbalanceados.
AUC-ROC	utilizada para avaliar a capacidade geral do modelo em diferenciar as duas classes ao longo de diferentes limiares de decisão.

2.1 Variável alvo

A variável original quality, composta por notas atribuídas por especialistas em uma escala de 3 a 8, foi transformada na variável binária binary quality, utilizada como variável alvo durante o treinamento dos modelos de aprendizado de máquina.

A nova classificação foi definida da seguinte forma:


- Alta qualidade: vinhos com nota maior ou igual a 7;
- Baixa/Média qualidade: vinhos com nota inferior a 7.

Essa transformação converteu o problema em uma tarefa de classificação binária, simplificando a interpretação dos resultados e permitindo comparar o desempenho de diferentes algoritmos de aprendizado supervisionado

3. Análise Exploratória dos Dados

Nesta etapa, foram analisadas as variáveis físico-químicas presentes no conjunto de dados com o objetivo de identificar padrões, tendências e relações entre os atributos. A análise exploratória permitiu compreender o comportamento de cada variável e avaliar seu potencial para diferenciar vinhos de alta e baixa/média qualidade. Essas informações serviram como base para as etapas de pré-processamento e para o desenvolvimento dos modelos de aprendizado de máquina.

3.1 Distribuição das variáveis




A análise dos histogramas demonstra que algumas variáveis apresentam comportamentos distintos entre as categorias de qualidade. Categorias como teor alcoólico, a acidez volátil, os sulfatos e o ácido cítrico apresentam distribuições diferentes entre os vinhos classificados como alta qualidade e baixa/média qualidade, sugerindo maior capacidade de discriminação entre as classes.

Por outro lado, variáveis como pH e açúcar residual apresentam distribuições bastante semelhantes entre as categorias, indicando um menor potencial para diferenciar vinhos de alta qualidade quando analisadas individualmente.

Esses resultados forneceram evidências iniciais sobre quais atributos poderiam exercer maior influência na previsão da qualidade dos vinhos. Essa hipótese foi posteriormente validada durante a etapa de desenvolvimento dos modelos, por meio da análise da importância das variáveis e da interpretação dos resultados obtidos.

3.2 Distribuição da Qualidade por Faixas de Álcool e pH




Com o agrupamento das variáveis em faixas de valores, foi possível comparar a distribuição dos vinhos classificados como Alta qualidade e Baixa/Média qualidade em diferentes intervalos de teor alcoólico e pH.

Observa-se que a faixa de 12,1% a 14,9% de teor alcoólico concentra a maior proporção de vinhos classificados como Alta qualidade, representando aproximadamente 51% das amostras dessa faixa. Esse resultado indica uma associação positiva entre maiores concentrações de álcool e a qualidade final do vinho, sugerindo que o teor alcoólico é um atributo relevante para a classificação dos vinhos.

Em contrapartida, a análise das faixas de pH não evidenciou diferenças significativas entre as categorias de qualidade. A distribuição das amostras permaneceu semelhante ao longo dos intervalos analisados, indicando que essa variável não apresentou associação positiva com a qualidade dos vinhos, quando considerada de forma isolada.


3.3 Faixas complementares (acidez fixa, açúcar residual, ácido cítrico)



Observa-se que a acidez fixa apresenta maior concentração de amostras na faixa entre 7,1 e 9,0 g/L, abrangendo vinhos classificados tanto como Alta qualidade quanto Baixa/Média qualidade. Embora seja possível notar uma proporção ligeiramente maior de vinhos de alta qualidade nas faixas superiores, essa variável demonstra apenas uma associação positiva fraca com a qualidade, indicando influência limitada quando analisada de forma isolada.

Em relação ao açúcar residual, verifica-se que a maior parte dos vinhos apresenta concentrações inferiores a 3 g/L, característica esperada para vinhos tintos secos. A distribuição entre as categorias de qualidade permanece bastante semelhante em todas as faixas analisadas, sugerindo que essa variável possui baixo poder discriminatório e pouca contribuição para a classificação da qualidade dos vinhos.

3.4 Correlações entre variáveis



O teor alcoólico apresentou a maior correlação positiva com a qualidade ($r = 0,484$), indicando que vinhos com maior concentração de álcool tendem a receber avaliações mais elevadas. Esse comportamento pode estar relacionado a processos de fermentação mais completos e ao uso de uvas mais maduras, características frequentemente associadas a vinhos de melhor qualidade.

A segunda variável com maior associação positiva foi a concentração de sulfatos ($r = 0,257$). Os resultados indicam que níveis adequados de sulfatos contribuem para a conservação do vinho, reduzindo processos de oxidação e preservando características sensoriais importantes ao longo do armazenamento.

O ácido cítrico também apresentou correlação positiva ($r = 0,241$), sugerindo que maiores concentrações dessa substância estão associadas a vinhos de melhor qualidade. Além de contribuir para o frescor e equilíbrio do sabor, essa variável apresentou diferenças expressivas entre as categorias analisadas, reforçando seu potencial como atributo preditivo.




4. Desenvolvimento dos modelos

Após as etapas de análise exploratória e pré-processamento dos dados, foram treinados três modelos de classificação com diferentes níveis de complexidade. O objetivo foi comparar abordagens distintas e identificar qual delas apresentou melhor capacidade para classificar vinhos de Alta qualidade e Baixa/Média qualidade.

Modelo	Características
Logistic Regression — baseline	Modelo linear utilizado como referência inicial. Permite comparar se modelos mais complexos realmente oferecem ganhos de desempenho na classificação dos vinhos.
Random Forest — modelo intermediário	Modelo baseado em múltiplas árvores de decisão, escolhido por sua robustez, boa capacidade de generalização e desempenho em conjuntos de dados desbalanceados.
XGBoost — modelo avançado	Modelo de Gradient Boosting utilizado por seu alto desempenho em problemas de classificação tabular, sendo capaz de capturar relações complexas entre as variáveis físico-químicas.


4.1 Interpretação das Matrizes de Confusão

Matrizes de confusão — conjunto de teste




O Random Forest identificou corretamente 22 dos 32 vinhos de alta qualidade presentes no conjunto de teste, mantendo também um número reduzido de classificações

incorretas entre os vinhos de baixa/média qualidade. Esse comportamento explica seu melhor resultado de F1-Score na avaliação inicial.



A comparação das métricas mostra que o Random Forest apresentou o melhor desempenho na avaliação inicial, obtendo os maiores valores de F1-Score, Precision e AUC-ROC entre os modelos avaliados. Esses resultados indicam que o algoritmo apresentou o melhor equilíbrio entre identificar corretamente os vinhos de alta qualidade e reduzir classificações incorretas, sendo o modelo mais consistente nesta primeira etapa do estudo.

4.2 Análise das médias por classe



A análise dos resultados permitiu identificar as principais características associadas aos vinhos classificados como de alta qualidade. Entre as variáveis o teor alcoólico apresentou a maior correlação positiva com a qualidade, indicando que vinhos com maior concentração de álcool tendem a receber melhores avaliações. Da mesma forma, maiores concentrações de ácido cítrico e sulfatos também estiveram associadas aos vinhos de melhor qualidade, sugerindo maior equilíbrio sensorial e melhores condições de conservação.

Em contrapartida, a acidez volátil apresentou a maior correlação negativa com a qualidade, evidenciando que concentrações elevadas desta variável estão relacionadas a vinhos de menor qualidade. Também foi observado que menores níveis de dióxido de enxofre total tendem a estar presentes nos vinhos melhor avaliados, indicando processos produtivos mais controlados e menor necessidade de intervenção química.

Esses resultados demonstram que determinadas características físico-químicas podem ser utilizadas como indicadores de qualidade durante o processo de produção. Dessa forma, o modelo desenvolvido pode servir como uma ferramenta de apoio ao controle de qualidade, auxiliando na identificação antecipada de lotes com maior potencial de qualidade e contribuindo para uma tomada de decisão mais rápida e baseada em dados.

5. Otimização dos modelos


Após a comparação inicial entre os algoritmos, foram realizadas etapas adicionais de otimização com o objetivo de melhorar o desempenho dos modelos e aumentar a capacidade de classificação dos vinhos de alta qualidade.

Foram avaliadas quatro estratégias distintas:

- ajuste do limiar de classificação (*threshold tuning*);
- otimização de hiperparâmetros;
- criação de novas variáveis (*feature engineering*);
- comparação de diferentes técnicas de balanceamento das classes.


Todas as estratégias foram avaliadas utilizando o mesmo conjunto de teste e as métricas definidas anteriormente (F1-Score, Precision, Recall e AUC-ROC).

5.1 Ajuste do Threshold



- O threshold padrão de classificação (0,50) nem sempre representa o melhor ponto de decisão para problemas com classes desbalanceadas. Por esse motivo, foi analisado o comportamento das métricas Precision, Recall e F1-Score para diferentes valores de threshold.
- Observa-se que o Random Forest atingiu seu melhor desempenho com threshold 0,560, elevando o F1-Score de 0,638 para 0,646.
- Para o XGBoost, o melhor resultado ocorreu com threshold 0,942, tornando o modelo mais criterioso ao classificar um vinho como de alta qualidade. Essa estratégia reduziu o Recall, porém aumentou significativamente a Precision (85,7%), resultando no melhor F1-Score obtido durante o projeto (0,679).

5.2 Comparação das Estratégias de Otimização



Os experimentos demonstraram que o maior ganho de desempenho foi obtido por meio da combinação entre o XGBoost, o ajuste de hiperparâmetros e a otimização do threshold de classificação. Essa estratégia alcançou F1-Score de 0,679, superando o melhor modelo da etapa inicial.

Em contrapartida, técnicas como Feature Engineering e métodos alternativos de balanceamento não apresentaram ganhos significativos, indicando que o conjunto original de variáveis e o uso do SMOTE já eram suficientes para representar adequadamente o problema.

6. Modelo final

Após a comparação entre os algoritmos e a realização das etapas de otimização, o modelo selecionado para este projeto foi o XGBoost com threshold otimizado (0,942), por apresentar o melhor equilíbrio entre as métricas de avaliação utilizadas.

métrica	métrica
F1-Score	67,9%
Precision	85,7%
Recall	56,3%
AUC-ROC	90,0%

6.1 Principais variáveis identificadas

- Álcool
- Acidez volátil
- Sulfatos
- Ácido cítrico

6.2 Aplicação prática

O modelo desenvolvido pode ser utilizado como uma ferramenta de apoio ao controle de qualidade, permitindo a classificação preliminar dos vinhos a partir de suas características físico-químicas. Dessa forma, lotes com maior probabilidade de serem classificados como Alta qualidade podem ser priorizados para avaliação sensorial, enquanto lotes com menor potencial podem ser analisados antecipadamente, auxiliando na tomada de decisão durante o processo produtivo.

7. Apêndice

Este apêndice reúne os materiais complementares desenvolvidos durante a execução do projeto, permitindo o acesso ao código-fonte, à apresentação e ao vídeo de demonstração.

7.1 Repositório do Projeto

O código-fonte completo, juntamente com o notebook desenvolvido, os arquivos utilizados para treinamento dos modelos, gráficos gerados e instruções para reprodução dos experimentos, está disponível no repositório GitHub:

Repositório:

<https://github.com/tatireginas/wine-quality-classification>

7.2 Vídeo Pitch

O vídeo de apresentação do projeto, contendo os principais objetivos, metodologia, resultados e conclusões, pode ser acessado pelo link abaixo:

Vídeo: <https://youtu.be/yRq3zXrrrOg>

7.3 Apresentação

A apresentação utilizada durante o vídeo pitch, contendo os principais gráficos e resultados do projeto, está disponível no repositório:

Slides: `wine_storytelling_eda.pptx`